

LİTERATÜR TARAMASI | HAFTA 1

Beratcan Polat

Konu ve amaç. Bu rapor, UCI Diabetes 130-US Hospitals (1999-2008) veri kümesiyle diyabet hastalarının hastaneye yeniden yatışını inceleyen üç çalışmayı değerlendirir. Çalışmalar sırasıyla klinik öznitelik oluşturma, hasta gruplarını keşfetme ve tahmin zamanına uygun değerlendirme konularında projeye yol gösterir. Veri kümesinde 101.766 hastane yatışı ve readmitted alanında NO, >30 ve <30 kategorileri bulunur [4].

1. Klinik öznitelikler ve birleşik risk puanı

Jibril, Kumar ve Ahmad (2026), Beyond the Black Box: Clinically Engineered Features and a Composite Risk Score for Diabetes Readmission Prediction [1].

Araştırma sorusu ve yöntem. Yazarlar, karmaşık bir algoritma kurmanın ötesinde, hastane kayıtlarından klinik olarak anlamlı yeni değişkenler üretmenin yeniden yatış tahminine katkısını araştırır. UCI veri kümesinden 40.000 yatış kaydı kullanılmıştır. Önceki hastane başvuruları, ilaç yükü, laboratuvar ve işlem yoğunluğu, tanı grupları ve yaş gibi bilgilerden 20 türetilmiş öznitelik oluşturulmuştur. Lojistik regresyon ve ağaç tabanlı modeller; XGBoost, LightGBM ve Extra Trees'i lojistik regresyonla birleştiren stacking modeliyle karşılaştırılmıştır. SHAP, değişkenlerin model kararlarına katkısını açıklamak için kullanılmıştır.

Temel bulgular. Stacking modeli ROC-AUC 0,7042 ve average precision (AP) 0,6678 değerlerine ulaşmıştır. Tek başına XGBoost'un ROC-AUC değeri 0,7037'dir; ayrıca XGBoost daha yüksek recall (0,6323) ve F1 (0,6246) vermiştir. Dolayısıyla stacking modelinin AUC üstünlüğü çok küçüktür. Makalede önceki yatışlar, laboratuvar işlemleri, ilaç sayısı ve yatış süresi etkili öznitelikler arasında yer alır.

Eleştirel değerlendirme ve projeye katkı. Çalışma, öznitelik mühendisliği ve model açıklaması için yararlı örnekler sunar. Buna karşılık makalede ham özniteliklerle türetilmiş öznitelikleri doğrudan karşılaştıran tam bir ablation deneyi ve dış doğrulama yoktur. Projede önce basit bir temel model kurulup yeni öznitelikler eklendiğinde AP ve ROC-AUC'deki değişim ayrı ayrı ölçülmelidir. SHAP sonuçları nedensel etki olarak yorumlanmamalıdır.

2. Kümeleme ile hasta profillerini keşfetme

Villanueva-Rueda ve arkadaşları (2025), Cluster analysis for the prevention of hospital readmission of diabetic patients [2].

Araştırma sorusu ve yöntem. Çalışma, benzer klinik ve demografik özellikler taşıyan hastaları gruplandırmayı amaçlar. Aynı UCI veri kümesinden 5.000 kayıt örneklenmiştir. Eksik değerler ve kategorik değişkenler işlendiğinde k-means ve PAM (medoid tabanlı kümeleme) uygulanmış; farklı öznitelik seçimi yöntemleri ve Simulated Annealing denenmiştir. Küme kalitesi, dirsek yöntemi/WCSS ve silhouette skoru ile incelenmiştir.

Temel bulgular. İki kümeli temel denemede k-means için silhouette 0,53, PAM için 0,50 olarak raporlanmıştır. Simulated Annealing ile seçilen değişkenler kullanıldığında beş küme için 0,99 silhouette bildirilmiştir. Seçilen değişkenler arasında A1Cresult ve bazı diyabet ilaçları bulunur; farklı seçim yöntemleri farklı hasta özelliklerini öne çıkarmıştır.

Eleştirel değerlendirme ve projeye katkı. Silhouette, kümelerin birbirinden ayrılığını ölçer; yeniden yatışı tahmin etme doğruluğu veya yeniden yatışın gerçekten azaldığı anlamına gelmez. Sonuçlar yalnızca 5.000 kayıtlık örnek üzerinde verilmiştir. Projede kümeleme keşif amaçlı kullanılabilir; etiket küme oluşturulurken kullanılmadan, sonrasında her kümedeki 30 günlük yeniden yatış oranı incelenebilir. Çok yüksek silhouette değeri ayrıca küme büyüklükleri ve klinik anlam açısından kontrol edilmelidir.

3. Tahmin zamanı ve hasta bazlı doğrulama

Rajpoot (2026), Does Discharge-Time Information Improve 30-Day Readmission Prediction? A Patient-Disjoint Evaluation in the UCI Diabetes 130-US Hospitals Cohort [3].

Araştırma sorusu ve yöntem. Bu ön baskı, hastaneye girişte bilinen bilgilerle taburculuğa kadar edinilen bilgilerin 30 gün içinde yeniden yatış tahminine katkısını karşılaştırır. Temizlik sonrası 99.340 yatış ve 69.987 hasta kalmıştır. Hedef <30 kategorisidir; pozitif oranı yaklaşık %11,4'tür. Giriş anında kullanılabilen 10 öznitelik ile taburculukta bilinen 46 öznitelik ayrı modellenmiştir. L2 lojistik regresyon ve histogram gradient boosting değerlendirilmiştir. Aynı hastanın kayıtları eğitim ve test kümelerine dağılmayacak biçimde bölünmüştür.

Temel bulgular. Test verisinde AUROC giriş modelinde 0,631, taburculuk modelinde 0,677; AP sırasıyla 0,206 ve 0,237'dir. Taburculuk modelinin F2 eşik noktasında duyarlılığı 0,789, özgüllüğü 0,422'dir; kayıtların %60,2'sine uyarı vermektedir. Ek bilgi ölçülebilir fakat sınırlı bir iyileşme sağlamıştır.

Eleştirel değerlendirme ve projeye katkı. Özniteliklerin tahmin anında mevcut olup olmadığını belirlemek ve hasta bazlı bölme yapmak veri sızıntısı riskini azaltır. Çalışma hakem değerlendirmesinden geçmemiş bir SSRN ön baskısıdır; veriler tarihsel, dış doğrulama yoktur. Projede eşik seçimi test kümesi görülmeden yapılmalı; AUROC yanında AP, duyarlılık ve yanlış alarm yükü raporlanmalıdır.

4. Üç çalışmanın birlikte değerlendirilmesi

Üç yayın aynı veri kaynağını kullanmasına rağmen farklı sorular sorar. Jibril ve arkadaşları öznitelik üretimi ile genel yeniden yatış riskini modeller; Villanueva-Rueda ve arkadaşları etiketsiz hasta gruplarını araştırır; Rajpoot ise 30 gün içindeki yeniden yatışı ve bilginin ne zaman mevcut olduğunu değerlendirir. Bu nedenle silhouette ile AUC aynı ölçekte değildir. Ayrıca farklı hedef tanımları ve örneklem büyüklükleri nedeniyle iki sınıflandırma çalışmasının AUC değerleri doğrudan bir model yarışı gibi karşılaştırılmamalıdır.

Ortak güçlü yön: Her çalışma ham tabloyu yalnızca bir algoritmaya vermekten öte bir tasarım kararı öne çıkarır: anlamlı değişkenler, hasta profilleri veya geçerli değerlendirme. **Ortak sınır:** Veri 1999-2008 dönemine aittir; bu yayınlar bugünkü hastanelerde klinik kullanım için dış ve ileriye dönük doğrulama sağlamaz. Kümeleme çalışmasının yüksek silhouette sonucu da klinik yarar kanıtı sayılmaz.

5. Dönem projesine uygulanabilir çalışma planı

- 1. Hedefi sabitle:** readmitted = <30 değerini pozitif sınıf, NO ve >30 değerlerini negatif sınıf olarak tanımla. Bu seçim raporun başında açıkça yazılmalı; farklı hedeflerle elde edilen sonuçlar karıştırılmamalıdır.
- 2. Veriyi güvenli biçimde böl:** patient_nbr yalnızca aynı hastanın kayıtlarını bir arada tutmak için kullanılsın; encounter_id ve patient_nbr modele girmesin. Eksik değer doldurma, kodlama ve eşik seçimi yalnızca eğitim verisi içinde öğrenilsin.
- 3. Önce temel modelleri kur:** Lojistik regresyon ile ağaç tabanlı bir model karşılaştırılsın. Daha sonra önceki başvuru sayıları, ilaç yükü ve tanı grupları gibi türetilmiş öznitelikler eklenerek katkıları ayrı bir deneyde ölçülsün.
- 4. Ek keşif yap:** Kümeleme uygulanırsa küme sayısı, silhouette ve hasta profilleri raporlansın. Yeniden yatış etiketi küme kurarken kullanılsın; her kümenin yeniden yatış oranı sonradan incelensin.
- 5. Sonuçları uygun metriklerle sun:** 30 günlük pozitif sınıf azınlıkta olduğu için accuracy tek başına yeterli değildir. AP, ROC-AUC, recall, precision, F1, karmaşıklık matrisi ve seçilen eşikte uyarı oranı birlikte raporlansın.

6. Kaynakça

- [1] Jibril, A. U., Kumar, A. S. ve Ahmad, A. S. (2026). Beyond the Black Box: Clinically Engineered Features and a Composite Risk Score for Diabetes Readmission Prediction. International Journal of Computer Applications, 187(136), 37-43. doi:10.5120/ijca07865afa79b1
- [2] Villanueva-Rueda, C. G., Chávez-Bosquez, Ó., Hernández-Ocaña, B. ve Hernández-Torruco, J. (2025). Cluster analysis for the prevention of hospital readmission of diabetic patients. Tecnura, 29(86), 59-74. doi:10.14483/22487638.24061
- [3] Rajpoot, B. (2026). Does Discharge-Time Information Improve 30-Day Readmission Prediction? A Patient-Disjoint Evaluation in the UCI Diabetes 130-US Hospitals Cohort. SSRN ön baskısı. doi:10.2139/ssrn.7154739
- [4] Clore, J., Cios, K., DeShazo, J. ve Strack, B. (2014). Diabetes 130-US Hospitals for Years 1999-2008 [Veri kümesi]. UCI Machine Learning Repository. doi:10.24432/C5230J