

LİTERATÜR TARAMASI | HAFTA 1

Beratcan Polat

Konu ve amaç. Bu rapor, UCI Diabetes 130-US Hospitals (1999-2008) veri kümesiyle diyabet hastalarının hastaneye yeniden yatışını inceleyen üç çalışmayı değerlendirir. Çalışmalar sırasıyla klinik öznitelik oluşturma, hasta gruplarını keşfetme ve tahmin zamanına uygun değerlendirme konularında projeye yol gösterir. Veri kümesinde 101.766 hastane yatışı ve readmitted alanında NO, >30 ve <30 kategorileri bulunur [4].

1. Klinik öznitelikler ve birleşik risk puanı

Jibril, Kumar ve Ahmad (2026), Beyond the Black Box: Clinically Engineered Features and a Composite Risk Score for Diabetes Readmission Prediction [1].

Araştırma sorusu ve yöntem. Yazarlar, karmaşık bir algoritma kurmanın ötesinde, hastane kayıtlarından klinik olarak anlamlı yeni değişkenler üretmenin yeniden yatış tahminine katkısını araştırır. UCI veri kümesinden 40.000 yatış kaydı kullanılmıştır. Önceki hastane başvuruları, ilaç yükü, laboratuvar ve işlem yoğunluğu, tanı grupları ve yaş gibi bilgilerden 20 türetilmiş öznitelik oluşturulmuştur. Lojistik regresyon ve ağaç tabanlı modeller; XGBoost, LightGBM ve Extra Trees'i lojistik regresyonla birleştiren stacking modeliyle karşılaştırılmıştır. SHAP, değişkenlerin model kararlarına katkısını açıklamak için kullanılmıştır.

Temel bulgular. Stacking modeli ROC-AUC 0,7042 ve average precision (AP) 0,6678 değerlerine ulaşmıştır. Tek başına XGBoost'un ROC-AUC değeri 0,7037'dir; ayrıca XGBoost daha yüksek recall (0,6323) ve F1 (0,6246) vermiştir. Dolayısıyla stacking modelinin AUC üstünlüğü çok küçüktür. Makalede önceki yatışlar, laboratuvar işlemleri, ilaç sayısı ve yatış süresi etkili öznitelikler arasında yer alır.

Benim değerlendirmem. Öznitelik mühendisliği ve model açıklaması açısından bu çalışmayı yararlı buldum. Ancak makalede ham ve türetilmiş öznitelikleri doğrudan karşılaştıran tam bir deney ile dış doğrulama bulunmuyor. Bu nedenle stacking modelinin çok küçük AUC farkını kesin bir üstünlük olarak görmüyorum. SHAP sonuçlarını da değişkenlerin neden olduğu etkiler değil, modelin kullandığı ilişkiler olarak yorumluyorum.

2. Kümleme ile hasta profillerini keşfetme

Villanueva-Rueda ve arkadaşları (2025), Cluster analysis for the prevention of hospital readmission of diabetic patients [2].

Araştırma sorusu ve yöntem. Çalışma, benzer klinik ve demografik özellikler taşıyan hastaları gruplandırmayı amaçlar. Aynı UCI veri kümesinden 5.000 kayıt örneklenmiştir. Eksik değerler ve kategorik değişkenler işlendiğinde k-means ve PAM (medoid tabanlı kümleme) uygulanmış; farklı öznitelik seçimi yöntemleri ve Simulated Annealing denenmiştir. Küme kalitesi, dirsek yöntemi/WCSS ve silhouette skoru ile incelenmiştir.

Temel bulgular. İki kümeli temel denemede k-means için silhouette 0,53, PAM için 0,50 olarak raporlanmıştır. Simulated Annealing ile seçilen değişkenler kullanıldığında beş küme için 0,99 silhouette bildirilmiştir. Seçilen değişkenler arasında A1Cresult ve bazı diyabet ilaçları bulunur; farklı seçim yöntemleri farklı hasta özelliklerini öne çıkarmıştır.

Benim değerlendirmem. Kümelenin hasta profillerini anlamak için yararlı olabileceğini gördüm. Bununla birlikte silhouette yalnızca kümelerin ayrılığını ölçüyor; yeniden yatış tahmininin doğruluğunu veya yeniden yatışın azaldığını göstermiyor. Çalışmanın 5.000 kayıtlık bir örnekle yapılması ve çok yüksek silhouette değerinin klinik karşılığının açık olmaması nedeniyle sonucu temkinli yorumluyorum.

3. Tahmin zamanı ve hasta bazlı doğrulama

Rajpoot (2026), Does Discharge-Time Information Improve 30-Day Readmission Prediction? A Patient-Disjoint Evaluation in the UCI Diabetes 130-US Hospitals Cohort [3].

Araştırma sorusu ve yöntem. Bu ön baskı, hastaneye girişte bilinen bilgilerle taburculuğa kadar edinilen bilgilerin 30 gün içinde yeniden yatış tahminine katkısını karşılaştırır. Temizlik sonrası 99.340 yatış ve 69.987 hasta kalmıştır. Hedef <30 kategorisidir; pozitif oranı yaklaşık %11,4'tür. Giriş anında kullanılabilen 10 öznitelik ile taburculukta bilinen 46 öznitelik ayrı modellenmiştir. L2 lojistik regresyon ve histogram gradient boosting değerlendirilmiştir. Aynı hastanın kayıtları eğitim ve test kümelerine dağılmayacak biçimde bölünmüştür.

Temel bulgular. Test verisinde AUROC giriş modelinde 0,631, taburculuk modelinde 0,677; AP sırasıyla 0,206 ve 0,237'dir. Taburculuk modelinin F2 eşik noktasında duyarlılığı 0,789, özgüllüğü 0,422'dir; kayıtların %60,2'sine uyarı vermektedir. Ek bilgi ölçülebilir fakat sınırlı bir iyileşme sağlamıştır.

Benim değerlendirmem. Bu çalışmada en dikkat çekici bulduğum nokta, bir bilginin hastaneye girişte mi yoksa taburculukta mı elde edildiğinin ayrı ele alınmasıdır. Aynı hastanın kayıtlarını eğitim ve test arasında ayırmamak da sonuçlara güven açısından önemli görünüyor. Makalenin hakem değerlendirmesinden geçmemiş bir SSRN ön baskısı olması, verilerin eski olması ve dış doğrulama bulunmaması nedeniyle bulguları kesin bir klinik sonuç olarak almıyorum.

4. Üç çalışmanın birlikte değerlendirilmesi

Üç yayın aynı veri kaynağını kullanmasına rağmen farklı sorular sorar. Jibril ve arkadaşları öznitelik üretimi ile genel yeniden yatış riskini modeller; Villanueva-Rueda ve arkadaşları etiketsiz hasta gruplarını araştırır; Rajpoot ise 30 gün içindeki yeniden yatışı ve bilginin ne zaman mevcut olduğunu değerlendirir. Bu nedenle silhouette ile AUC aynı ölçekte değildir. Ayrıca farklı hedef tanımları ve örneklem büyüklükleri nedeniyle iki sınıflandırma çalışmasının AUC değerleri doğrudan bir model yarışı gibi karşılaştırılmamalıdır.

Ortak güçlü yön: Her çalışma ham tabloyu yalnızca bir algoritmaya vermekten öte bir tasarım kararı öne çıkarır: anlamlı değişkenler, hasta profilleri veya geçerli değerlendirme. **Ortak sınır:** Veri 1999-2008 dönemine aittir; bu yayınlar bugünkü hastanelerde klinik kullanım için dış ve ileriye dönük doğrulama sağlamaz. Kümeleme çalışmasının yüksek silhouette sonucu da klinik yarar kanıtı sayılmaz.

5. Literatür taramasından çıkardığım sonuçlar

Bu üç makaleyi okurken aynı veri seti kullanılsa bile araştırma sorusunun ve hedef değişkenin değişebildiğini fark ettim. Jibril ve arkadaşlarının genel yeniden yatış için verdiği sonuçlarla Rajpoot'un 30 gün içindeki yeniden yatış sonuçlarını doğrudan karşılaştırmanın doğru olmayacağını düşünüyorum. Kümeleme makalesindeki silhouette değeri de sınıflandırma başarısıyla aynı şeyi ölçmüyor.

Benim için en yararlı noktalar, Jibril ve arkadaşlarının klinik bilgilerden yeni değişkenler üretmesi, Villanueva-Rueda ve arkadaşlarının hasta profillerine farklı bir açıdan bakması ve Rajpoot'un aynı hastaya ait kayıtları eğitim ile test arasında ayırmaması oldu. Bu çalışmalar, yalnızca yüksek bir skor aramak yerine sonucun nasıl elde edildiğini de sorgulamam gerektiğini gösterdi.

Özellikle 30 günlük yeniden yatış gibi az görülen bir durumu incelerken accuracy değerinin tek başına yeterli olmayacağını anladım. AP, duyarlılık ve yanlış alarm sayısı gibi ölçüler de sonucun yorumunu değiştiriyor. Üç çalışmadan çıkardığım ortak sonuç, bir modelin puanını değerlendirirken verinin nasıl hazırlandığına ve hangi hasta grubunda test edildiğine de bakmam gerektiği oldu.

6. Kaynakça

- [1] Jibril, A. U., Kumar, A. S. ve Ahmad, A. S. (2026). Beyond the Black Box: Clinically Engineered Features and a Composite Risk Score for Diabetes Readmission Prediction. International Journal of Computer Applications, 187(136), 37-43. doi:10.5120/ijca07865afa79b1
- [2] Villanueva-Rueda, C. G., Chávez-Bosquez, Ó., Hernández-Ocaña, B. ve Hernández-Torruco, J. (2025). Cluster analysis for the prevention of hospital readmission of diabetic patients. Tecnura, 29(86), 59-74. doi:10.14483/22487638.24061
- [3] Rajpoot, B. (2026). Does Discharge-Time Information Improve 30-Day Readmission Prediction? A Patient-Disjoint Evaluation in the UCI Diabetes 130-US Hospitals Cohort. SSRN ön baskısı. doi:10.2139/ssrn.7154739
- [4] Clore, J., Cios, K., DeShazo, J. ve Strack, B. (2014). Diabetes 130-US Hospitals for Years 1999-2008 [Veri kümesi]. UCI Machine Learning Repository. doi:10.24432/C5230J