Literatür Taraması ve Benzer Çalışmalar

Diyabetli hastalarda 30 günlük yeniden yatış tahmini; özniteliklerin klinik anlamı, sınıf dengesizliği ve değerlendirme tasarımı açısından ele alınmaktadır. UCI Diabetes 130-US Hospitals veri seti, 1999-2008 dönemine ait 101.766 hastane yatış kaydı içermektedir. Bhuvan ve arkadaşları [1], farklı sınıflandırıcılar, öznitelik çıkarma deneyleri ve maliyet duyarlı eşik seçimiyle geçmiş yatışların ve taburculuk durumunun önemini göstermiştir. Bununla birlikte, hesaplanan tasarruf müdahalenin yeniden yatışı önleyeceği varsayımına dayanmaktadır. Zhu ve arkadaşlarının [2] çalışması, yeniden yatışla ilişkili risk özelliklerinin değerlendirilmesini konu edinmektedir. Nathan ve arkadaşları [3], UCI verisinde lojistik regresyon ve ağaç tabanlı modelleri karşılaştırmış; SMOTE ve sınıf ağırlıklarıyla dengesizliği ele almıştır. Ancak [1] ve [3] çalışmalarındaki bölme açıklamaları hasta bazında ayrımı açıkça güvence altına almamaktadır.

Topluluk öğrenmesi ve öznitelik mühendisliği, tahmin başarısını geliştirmek için kullanılan diğer yaklaşımlardır. Doğru ve arkadaşları [4], lojistik regresyon, karar ağacı, Random Forest ve Gradient Boosting çıktılarının SVM üst öğrenicisiyle birleştirildiği bir model önermiştir. Üç veri setinde değerlendirilen yaklaşım yöntemsel katkı sunsa da erken diyabet risk tahmini için bildirilen doğruluklar, 30 günlük yeniden yatış başarısıyla doğrudan karşılaştırılamaz. Jibril ve arkadaşları [5], klinik olarak türetilmiş öznitelikler ve bileşik risk skorunu stacking modeliyle birleştirmiştir. Stacking ve XGBoost için ROC-AUC değerlerinin 0,7042 ve 0,7037 olması, ek model karmaşıklığının sınırlı kazancına işaret etmektedir. Ham ve türetilmiş öznitelikleri ayrı değerlendiren deneylerin eksikliği, öznitelik mühendisliğinin bağımsız katkısını belirsiz bırakmaktadır.

Brothers ve arkadaşları [6], MIMIC-IV verisinde tip 2 diyabet dahil üç kronik hastalık grubunun yeniden yatışını incelemiş; SMOTE, CTGAN ve TVAE ile veri artırmayı lojistik regresyon ve topluluk modelleriyle değerlendirmiştir. Sentetik üretimin yalnızca eğitim katlarında uygulanması veri sızıntısının önlenmesi açısından önemlidir. Bununla birlikte, tek merkezli veri kullanımı, dış doğrulama ve kalibrasyon değerlendirmesinin bulunmaması genellenebilirliği sınırlandırmaktadır. Villanueva-Rueda ve arkadaşları [7], UCI verisinden seçilen 5.000 kayıtta k-means, PAM ve benzetimli tavlama ile hasta profillerini araştırmıştır. Kümeleme, keşifsel analiz için yararlı olsa da yüksek silhouette değeri sınıflandırma başarısının veya yeniden yatışın önlendiğinin kanıtı değildir.

Alzahrani [8], UCI ve BRFSS verilerinde diferansiyel gizlilikli federe boosting, sinir ağı ve lojistik regresyonu karşılaştırmış; gizlilik bütçeleri boyunca sürekli üstün olan tek bir model bulunmadığını göstermiştir. Bu yaklaşım, gelecekteki çok merkezli çalışmalar için gizlilik-performans dengesini gündeme getirmektedir. Rajpoot [9], hasta bazında ayrılmış UCI verisinde taburculuk bilgilerinin eklenmesiyle ROC-AUC değerinin 0,631'den 0,677'ye yükseldiğini bildirmiştir. Ancak seçilen eşikte kayıtların %60,2'sinin uyarı üretmesi, yanlış alarm yükünün ayrıca değerlendirilmesi gerektiğini göstermektedir. Ön baskı niteliğindeki bu çalışma, özniteliklerin tahmin anında erişilebilirliğinin ve hasta bazında doğrulamanın önemini vurgulamaktadır.

Bu çalışmalar birlikte değerlendirildiğinde, hedef tanımı ve kohort seçimindeki farklılıkların başarı ölçütlerinin doğrudan karşılaştırılmasını güçleştirdiği görülmektedir. UCI verisinin geçmiş bir döneme ait olması ve dış doğrulama eksikliği de klinik genellenebilirliği sınırlandırmaktadır [3,5,9]. Çalışmamızda hedef, UCI etiketlemesine göre <30 pozitif; >30 ve NO negatif olacak şekilde tanımlanacaktır. Aynı hastanın farklı veri bölümlerinde bulunması önlenecek; eksik değer işlemleri, kodlama, öznitelik seçimi ve yeniden örnekleme yalnızca eğitim verisinde yürütülecektir. Lojistik regresyon ile ağaç tabanlı modeller aynı bölmelerde karşılaştırılacak, türetilmiş özniteliklerin katkısı ayrıca incelenecektir. ROC-AUC yanında ortalama kesinlik (AP), duyarlılık, kesinlik, F1, kalibrasyon ve yanlış alarm yükü raporlanacaktır. Eşik seçimi doğrulama verisinde yapılacak; öznitelik önemleri nedensel etki olarak yorumlanmayacaktır.

Kaynakça

[1] Bhuvan, M. S., Kumar, A., Zafar, A. ve Kishore, V. (2016). Identifying Diabetic Patients with High Risk of Readmission. *arXiv:1602.04257. Ön baskı.* https://doi.org/10.48550/arXiv.1602.04257

[2] Zhu, Q., Akkati, A. ve Hongwattanakul, P. (2016). Risk feature assessment of readmission for diabetes. *2016 IEEE International Conference on Bioinformatics and Biomedicine (BIBM), 538-543.* https://doi.org/10.1109/BIBM.2016.7822578

[3] Nathan, M., Sherifi, D. ve Muthusamy, V. (2025). Diabetes Patients' Readmission Prediction. *International Journal on Science and Technology, 16(4), IJSAT25049030.* https://www.ijsat.org/papers/2025/4/9030.pdf

[4] Doğru, A., Buyrukoğlu, S. ve Arı, M. (2023). A hybrid super ensemble learning model for the early-stage prediction of diabetes risk. *Medical & Biological Engineering & Computing, 61, 785-797.* https://doi.org/10.1007/s11517-022-02749-z

[5] Jibril, A. U., Kumar, A. S. ve Ahmad, A. S. (2026). Beyond the Black Box: Clinically Engineered Features and a Composite Risk Score for Diabetes Readmission Prediction. *International Journal of Computer Applications, 187(136), 37-43.* https://doi.org/10.5120/ijca07865afa79b1

[6] Brothers, T., Adhikari, K., Ramazani, M., Imtiaz, A. ve Al-Mamun, M. (2026). Synthetic data-augmented machine learning for 30-day readmission prediction in patients with chronic conditions: a retrospective real-world study. *BMJ Open, 16(4), e108273.* https://doi.org/10.1136/bmjopen-2025-108273

[7] Villanueva-Rueda, C. G., Chávez-Bosquez, O., Hernández-Ocaña, B. ve Hernández-Torruco, J. (2025). Cluster analysis for the prevention of hospital readmission of diabetic patients. *Tecnura, 29(86), 59-74.* https://doi.org/10.14483/22487638.24061

[8] Alzahrani, A. S. (2026). Revisiting Differentially Private Federated Learning for Tabular Data: A Matched-Accounting Benchmark of Boosting Versus DP-SGD. *Electronics, 15(16), 3597.* https://doi.org/10.3390/electronics15163597

[9] Rajpoot, B. (2026). Does Discharge-Time Information Improve 30-Day Readmission Prediction? A Patient-Disjoint Evaluation in the UCI Diabetes 130-US Hospitals Cohort. *SSRN. Ön baskı.* https://doi.org/10.2139/ssrn.7154739

Veri seti kaynağı

Clore, J., Cios, K., DeShazo, J. ve Strack, B. (2014). *Diabetes 130-US Hospitals for Years 1999-2008* [Veri seti]. UCI Machine Learning Repository. https://doi.org/10.24432/C5230J