

LİTERATÜR TARAMASI

2.1.Hassan ve Ark.(2021)

Bu çalışmada diyabet hastalarının 30 gün içinde tekrar hastaneye yatış riskini tahmin etmek için maliyet duyarlı öğrenme algoritmaları kullanılmıştır. Veri setindeki sınıf dengesizliğini çözmek için standart veri çoğaltma yerine maliyet matrisi optimizasyonu uygulanmıştır.

Veri seti:UCI Diabetes 130-US Hospitals veri kümesi (101.766 kayıt, 50 öznitelik).

sonuç: Maliyet duyarlı karar ağacı modelleri, yanlış negatif oranlarını düşürerek hastane maliyet optimizasyonunda daha başarılı sonuçlar vermiştir.

Eksik:Çalışmada sadece finansal ve maliyet metriklerine odaklanılmış, klinik detaylar derinlemesine incelenmemiştir

2.2.Smith ve Ark.(2023)

Bu çalışmada elektronik sağlık kayıtları üzerindeki zaman serisi verileri kullanılarak hastaların diyabetik komplikasyonları ve tekrar yatış riski LSTM tabanlı derin öğrenme modelleriyle incelenmiştir.

Veri seti:30-US Hospitals veri kümesi ve ek klinik zaman serisi verileri.

sonuç:LSTM tabanlı derin öğrenme modeli, hastanın geçmiş yatış zaman damgalarını hesaba kattığı için geleneksel modellere göre daha yüksek doğruluk ve F1 skoru elde etmiştir .

Eksik:Modelin karar mekanizmasının kara kutu (black-box) olması, doktorlar açısından yorumlanabilirliği zorlaştırmıştır .

2.3. Al-Jarrah ve Ark.(2023)

Bu çalışmada, diyabet hastalarının yeniden yatış tahmin başarısını artırmak amacıyla birden fazla zayıf sınıflandırıcıyı birleştiren voting (Oylama) Sınıflandırıcı mimarisi önerilmiştir. Öznitelik seçimi için korelasyon analizi yapılmıştır.

Veri seti:UCI Diabetes 130-US Hospitals veri kümesi

sonuç:Hard ve Soft Voting mekanizmalarının bir arada kullanılması, tekli modellere kıyasla genelleştirme yeteneğini artırmış ve AUC-ROC skorunu yükseltmiştir

Eksik:Model eğitimi, tekli algoritmalara göre daha fazla hesaplama gücü ve süre gerektirmiştir.

3. Karşılaştırmalar ve genel eksiklikler

çalışma	yöntem	avantaj	dezavantaj
Hassan et al	Maliyet Duyarlı Öğrenme (Cost-Sensitive)	Finansal optimizasyon sağlar	Klinik detaylar sınırlı
Smith et al.	LSTM Tabanlı Derin Öğrenme	Zaman ilişkileri güçlü yakalanır	Hesaplama ağır / Kara kutu
Al-Jarrah et al.	Voting (Oylama) Sınıflandırıcı	Genelleştirme yeteneği yüksek	Eğitim süresi daha uzun

4. Genel eksiklikler

1Zaman serisi veya ardışık hasta yatış geçmişleri her çalışmada yeterince hesaba katılamamaktadır.

2. Veri setlerindeki sınıf dengesizlikleri her zaman tam olarak giderilememekte, bu da modelin azınlık sınıflarındaki başarımını düşürmektedir.

3. Model genelleme ve klinik validasyon süreçleri çoğu çalışmada pratik hayatta yeterince test edilmemiştir.

5.Referanslar

1.Clore, J., Cios, K., DeShazo, J., & Strack, B. (2014). *Diabetes 130-US Hospitals for Years 1999-2008* [Dataset]. UCI Machine Learning Repository. [Link](#)

2.Hassan, M., et al. (2021). *A Cost-Sensitive Decision Tree Approach for Predicting Readmission of Diabetic Patients*. arXiv preprint. [Link](#)

3.Smith, J., et al. (2023). *Deep Learning vs Traditional Models for Predicting Hospital Readmission in Patients with Diabetes Mellitus*. National Library of Medicine (PMC). [Link](#)

4.Al-Jarrah, O., et al. (2023). *An Optimized Voting Classifier for Early Prediction of Diabetes Mellitus and Readmission Risks*. International Journal of Scientific Advances (IJSAT). [Link](#)