

Giriş ve Problem Tanımı

Bu literatür taramasında, "Diabetes 130-US Hospitals" veri seti ve diyabet risk analizine yönelik klinik veriler üzerinde gerçekleştirilen güncel makine öğrenmesi yaklaşımlarını inceledim. Temel amacım, hastaneye yeniden yatış (readmission) ve erken risk teşhisi problemlerinde literatürde sıkça karşılaşılan yüksek boyutlu öznitelik uzayı (feature space) ve veri gizliliği gibi zorlukların nasıl aşıldığını sentezleyerek, kendi projeme metodolojik bir zemin hazırlamaktır.

Literatürün Tematik Analizi

İncelediğim çalışmalar; model mimarisinin geliştirilmesi, veri ön işleme stratejileri ve hasta mahremiyeti olmak üzere üç temel boyutta kümelenmektedir:

1. Hibrit ve Topluluk (Ensemble) Modeller:

2023 yılında yayımlanan bir çalışmada, tekil algoritmaların (Random Forest, XGBoost vb.) sınırlarını aşmak amacıyla bu modellerin bir "Süper Öğrenici" (Super Ensemble) katmanında birleştirildiği görülmüştür. Bu birleşik mimarinin, erken aşama diyabet risk teşhisinde hem tahmin gücünü hem de modelin istikrarını (robustness) belirgin şekilde artırdığını tespit ettim.

2. Klinik Öznitelik Mühendisliği (Feature Engineering):

2016 tarihli bir diğer araştırmada, 50 civarındaki klinik özniteliklerin hastaneye yeniden yatış riski üzerindeki bağımsız etkileri analiz edilmiştir. Bu çalışma, yalnızca genel bir doğruluk oranına odaklanmak yerine; hastanın yaşı, laboratuvar test sonuçları ve düzenli kullandığı ilaç sayısı gibi spesifik değişkenlerin riske etkisini algoritmik olarak ağırlıklandırmış ve gereksiz değişkenleri eleyerek gürültüyü azaltmıştır.

3. Veri Gizliliği ve Merkeziyetsiz Öğrenme:

2026 tarihli oldukça güncel bir makalede, klinik sağlık verilerinin güvenliği ele alınmıştır. Verilerin merkezi bir veri tabanında toplanmadan işlenebilmesi için tablosal veriler üzerinde "Federe Öğrenme" (Federated Learning) ve "Diferansiyel Gizlilik" (Differential Privacy) konseptleri test edilmiş ve gizlilik ile tahmin doğruluğu arasında kurulabilecek optimum denge kanıtlanmıştır.

Sentez ve Değerlendirme

Literatürdeki bu farklı yaklaşımları bir araya getirdiğim şu analitik sonuçlara ulaştım:

- Mevcut çalışmaların büyük bir kısmı algoritma metriklerini (Accuracy, AUC) yükseltmeye odaklansa da, yapılandırılmış bir öznitelik seçimi yapılmadığında veri setindeki aşırı karmaşıklık gerçek dünya uygulanabilirliğini düşürmektedir.
- "Süper Öğrenici" gibi gelişmiş hibrit modellerin tahmin başarıları çok yüksek olmasına rağmen hesaplama maliyeti artmaktadır; bu noktada 2016'daki çalışmada önerilen titiz öznitelik eliminasyonunu uygulayarak veri boyutunu optimize etmek kritik bir gerekliliktir.

- c. Klinik veri analizlerinde yalnızca model performansı değil, siber güvenlik ve mahremiyet standartlarının da modern bir makine öğrenmesi hattında (pipeline) ne kadar hayati olduğu net bir şekilde görülmektedir.

Projeme Entegrasyon

Bu tarama sonucunda edindiğim bulguları doğrudan dönem projeme entegre etmeyi hedefliyorum. Python üzerinde modelimi kurgularken, veri temizleme aşamasında literatürdeki klinik öznetelik ağırlıklandırma prensiplerini referans alarak güçlü bir ön işleme (preprocessing) iskeleti oluşturacağım. Ardından, tek bir algoritmaya güvenmek yerine birden fazla modeli harmanlayan bir topluluk (ensemble) mimarisi kurarak başarı metriklerimi maksimize etmeyi planlıyorum. Çalışmamın bilimsel vizyonunu genişletmek adına ise, raporumun "Sınırlar ve Gelecek Çalışmalar" bölümünde modelimin Federe Öğrenme konseptiyle nasıl merkeziyetsiz ve güvenli bir yapıya dönüştürülebileceğine dair akademik çıkarımlara yer vereceğim.